

面向未知大场景的语义增强与结构感知主动覆盖式探索

李兆宇

2025 年 12 月 23 日

摘要

针对现有覆盖式探索方法多局限于室内小场景，在大尺度环境中面临定位累积误差显著、覆盖率受限等挑战，本文提出了一种基于语义增强与结构感知的层次化主动 SLAM 系统。该系统依托分层探索架构，创新性地构建了多通道奖励机制：融合语义密度、结构感知、前沿驱动及基础覆盖奖励，利用语义识别模块实时生成的语义流引导机器人高效探索高信息增益区域并突破局部受限空间。此外，系统引入语义回环检测模块，结合 NetVLAD 与语义指纹校准大场景下的累积漂移；并集成语义地图补全技术，利用场景先验推断观测盲区结构。在 Gibson 与 Matterport3D 数据集上的实验结果表明，该方法在未知大场景中显著提升了建图覆盖率、定位精度与探索效率。

关键词：主动 SLAM；语义导航；结构感知；层次化探索；大场景建图

1 介绍 (Introduction)




图 1: 传统几何探索与本文语义结构感知探索的对比。(a) 仅依赖几何边界的方法 (Baseline) 在复杂房间结构中容易陷入局部极值, 导致路径冗余与回溯; (b) 本文方法 (Ours) 利用语义密度与结构感知 (如门框识别), 引导机器人高效突破封闭区域, 直接穿过走廊探索新空间, 实现快速覆盖。

自主探索未知环境并构建高精度的环境地图 (Active SLAM) 是具身智能体 (Embodied Agents) 在灾后救援、家庭服务及工业巡检等领域实现自主任务的关键前提。与传统的被动式 SLAM 不同, 主动 SLAM 要求智能体根据当前的观测状态, 自主规划移动路径以最大化信息增益。近年来, 随着深度学习与强化学习的发展, 基于学习的探索方

法在室内导航任务中展现出了超越传统几何方法的潜力。然而，当应用场景从结构简单的单一房间扩展到大规模、非结构化的未知环境（Large-Scale Unknown Environments）时，现有的探索策略面临着严峻的挑战。

目前的覆盖式探索方法主要分为两类：基于几何边界（Frontier-based）的方法和基于端到端学习（Learning-based）的方法。传统的几何方法通常倾向于贪婪地探索最近的未知区域，在长走廊或纹理单一的大场景中极易陷入局部最优，导致频繁的路径回溯和冗余移动（如图 1(a) 所示）。虽然近年来基于深度强化学习（DRL）的方法（如 Active Neural SLAM）实现了端到端的探索策略，但大多仅依赖障碍物等几何信息作为输入，忽略了环境中的高层语义信息（如房间功能、物体分布）和拓扑结构特征（如门、通道）。这种语义缺失导致机器人在面对复杂大场景时，无法像人类一样理解“穿过门可能到达新房间”或“高密度物体区域值得重点探索”，从而限制了探索效率的进一步提升。此外，现有方法往往缺乏针对大场景的闭环修正机制，难以在长期运行中维持全局定位精度。

针对上述问题，本文提出了一种基于语义增强与结构感知的层次化主动 SLAM 系统。该系统在“全局规划-局部执行”的分层架构下，创新性地引入了多通道奖励机制。具体而言，我们集成 YOLOv8 实时构建多通道语义地图：一方面，利用“语义密度”（Semantic Density）作为启发式信号，引导机器人优先探索信息丰富的高价值区域；另一方面，设计“结构感知奖励”（Structure-Aware Reward），通过识别门框、狭窄通道等关键拓扑节点，激励机器人突破局部封闭空间，加速跨区域探索（如图 1(b) 所示）。此外，为了应对大场景下的感知不确定性，系统集成语义回环检测与地图补全模块。利用 NetVLAD 特征与语义指纹的融合匹配，有效校准长期探索产生的累积定位漂移；同时利用场景先验知识对观测盲区进行几何补全，进一步提升了建图的完整性与鲁棒性。

2 相关工作 (Related Work)

本节主要回顾与本文研究密切相关的三类工作：基于学习的层次化探索、语义辅助的主动探索，以及增强建图一致性与完整性的关键技术（语义回环检测与场景补全）。

2.1 基于学习的层次化探索

随着深度强化学习（DRL）的发展，数据驱动的方法逐渐取代了传统的几何边界法，成为主动探索的主流范式。为了解决长视距规划中的稀疏奖励问题，**层次化（Hierarchical）架构**被广泛采用。该领域的代表性工作 Active Neural SLAM (ANS) 提出了一种“全局-局部”双层策略：全局策略基于长期地图信息生成探索子目标，局部策略则负责具体的路径规划与避障。尽管 ANS 在室内中小场景中表现优异，但其决策输入主要依赖几何障碍物地图（Obstacle Map）和智能体位姿，缺乏对环境**语义信息**和**拓扑结构**的理解。在大尺度复杂环境中，仅凭几何信息难以区分“死胡同”与“关键通道”（如门框），导致全局规划容易陷入局部极值，且探索效率随场景尺度增加而显著下降。

2.2 语义辅助的主动探索

为了突破几何方法的局限性，近期研究开始利用**语义信息**来提供高层先验知识。语义不仅丰富了地图的表达，更能为探索决策提供“价值”判断。例如，GET (Goal-directed Exploration and Targeting) 框架结合了大语言模型 (LLM) 的空间推理能力，利用语义路标 (Semantic Landmarks) 在未知大场景中进行高效的目标搜索。然而，此类方法大多侧重于特定对象的**目标导航 (Object Goal Navigation)**，而非最大化全图覆盖率。与本文更相关的是利用语义进行覆盖优化的工作。然而，现有方法往往将语义视为离散的标签，未能充分利用**环境拓扑结构 (如门、走廊)**与**语义密度分布**之间的内在联系。本文提出的系统正是通过显式地利用“语义密度”和“结构特征”作为奖励信号，在保证探索方向正确性的同时，显著提升了覆盖效率。

2.3 语义回环检测与场景补全

在大规模未知环境的长期探索中，维护地图的全局一致性与完整性是两大核心挑战。

语义回环检测 (Semantic Loop Closure): 传统的基于几何或视觉特征 (如 ORB, SIFT) 的回环检测在大场景中容易因视角变化大或纹理重复 (Perceptual Aliasing) 而失效。近年来，融合**语义信息**的回环检测成为趋势。通过将场景中的语义对象 (如家具、房间功能区) 构建为拓扑节点，并结合 NetVLAD 等全局描述符提取语义指纹，可以显著提高回环检测在复杂环境下的鲁棒性。本文沿用这一思路，利用语义拓扑约束来校准长期探索产生的累积定位漂移。

语义场景补全 (Semantic Scene Completion, SSC): 由于传感器视角的限制，单帧观测往往是不完整的。语义场景补全技术旨在从稀疏的观测中推断出被遮挡区域的几何与语义信息。最新工作如 SEA (Semantic Map Prediction) 提出利用预测模块来推断未知区域的地图结构，并利用预测图与观测图的差异来引导机器人探索高不确定性区域。受此启发，本文的系统虽然侧重于基于奖励的规划，但也强调利用场景的结构化先验 (如房间的规则布局) 来辅助决策，通过“幻觉”出视野盲区内的潜在结构，为全局规划器提供更完整的环境上下文。

3 方法 (Methodology)

本章详细阐述所提出的面向未知大场景的语义增强型层次化主动 SLAM 系统。首先在 3.1 节介绍系统的整体架构；3.2 节描述基于语义感知的多通道地图构建方法；3.3 节重点阐述自监督可达性感知全局策略的设计与训练；3.4 节详细定义驱动高效探索的多通道语义奖励机制；最后在 3.5 节介绍用于维持全局一致性的语义回环检测与地图补全模块。

3.1 系统概览 (System Overview)

针对大尺度未知环境中的长视距探索与目标不可达问题，本文提出了一种包含**可达性感知 (Reachability-Awareness)** 的层次化导航架构。如图 2 所示，系统主要由三个交互模块组成：




图 2: 所提出的系统架构概览。系统集成双流感知（几何与语义）以构建多通道全局地图。可达性感知全局策略通过自监督 RPN 过滤不可达区域，生成长期目标，并由局部规划器执行。

- **感知与建图模块 (Perception & Mapping Module):** 作为系统的输入端，该模块接收 RGB 图像流。一方面利用 Neural SLAM 模块预测局部几何地图与智能体位姿；另一方面集成 YOLOv8 目标检测网络提取环境语义信息，构建包含几何与语义特征的全局多通道地图。
- **可达性感知全局策略 (Reachability-Aware Global Policy):** 该模块是决策核心，以全局地图状态为输入。不同于传统方法直接采样长期目标，本文引入了一个自监督可达性预测网络 (RPN)，利用历史探索经验实时评估候选目标的物理可达性，通过“掩码机制”抑制无效目标（如墙后或死胡同深处区域）的生成，输出高价值且可执行的长期目标点。
- **局部规划与执行模块 (Local Planning & Execution Module):** 利用解析路径规划器将长期目标规划为短期路径点，并由局部策略网络将其转化为具体的离散动作 (Move Forward, Turn Left, Turn Right) 以控制机器人移动。

3.2 语义感知与多通道地图构建

为了赋予机器人对环境内容的理解能力，系统维护一个 K 通道全局地图 $M_t \in \mathbb{R}^{H \times W \times K}$ ，主要包含以下关键通道：

3.2.1 几何通道

包含障碍物地图 M_{obs} 和探索状态地图 M_{exp} 。这两个通道通过 Neural SLAM 的解码器从当前观测帧预测得到，并利用位姿估计在全局坐标系下进行融合更新。

3.2.2 语义密度通道 (M_{sem})

为了捕捉高层环境特征，系统利用 YOLOv8 对每帧图像进行目标检测，获取语义对象集合 O_t 。对于地图上的每个网格单元 (i, j) ，其语义密度 $S_{i,j}$ 定义为该位置检测到的语义对象的置信度累积：

$$S_{i,j} = \sum_{k \in O_{i,j}} \mathbb{I}(c_k \in \mathcal{C}_{interest}) \cdot \text{conf}_k \quad (1)$$

其中 $O_{i,j}$ 是投影到该网格的对象集合， $\mathcal{C}_{interest}$ 为感兴趣的语义类别集合（如家具、电器等）， conf_k 为检测置信度。




图 3: 多通道语义地图构建可视化。系统从 RGB 观测中提取几何特征与语义对象，分别构建障碍物图、语义密度图（热力图表示区域信息丰富度）及结构特征图，这些通道共同组成了全局状态 S_t ，为后续的结构感知奖励计算提供基础。

高语义密度区域通常对应房间内部或功能密集区，是探索的高价值目标。

3.3 自监督可达性感知全局策略

现有的端到端全局策略往往容易生成位于未探索区域深处或障碍物内部的无效目标，导致机器人在不可达目标间反复震荡。为此，我们在全局策略网络中设计了一个可

达性预测分支，并提出了一种自监督训练机制。

3.3.1 网络架构

全局策略网络 π_G 包含一个共享的 CNN 特征提取器和三个功能头：

- **Actor Head:** 输出全局目标的空间概率分布 $\pi_{act}(g|S_t)$ 。
- **Critic Head:** 估计当前状态价值 $V(S_t)$ ，用于 PPO 算法的优势函数计算。
- **Reachability Head (RPN):** 输出一个与地图同尺寸的可达性概率图 $M_{reach} \in [0, 1]^{H \times W}$ 。其中， $M_{reach}(i, j)$ 表示如果将坐标 (i, j) 设为目标，局部规划器在规定步数 T_{local} 内成功到达的概率。

3.3.2 目标选择与掩码机制

在推理阶段，最终的目标选择不再仅依赖 Actor 的输出，而是由可达性图进行加权调制 (Masking)。修正后的目标概率分布 P_{final} 定义为：

$$P_{final}(g) = \text{Softmax}(\log \pi_{act}(g|S_t) + \alpha \cdot \log(M_{reach}(g) + \epsilon)) \quad (2)$$

其中 α 为调节系数。通过这种方式，位于墙后、地图外或死胡同深处等物理不可达区域的概率被显著抑制，强制智能体选择那些“既高价值又可执行”的目标点。

3.3.3 自监督训练

RPN 的训练不需要人工标注，而是完全利用机器人与环境交互的**历史经验回放**。我们构建一个经验缓冲区 $\mathcal{D} = \{(S_t, g_t, y_t)\}$ ，其中标签 $y_t \in \{0, 1\}$ 由实际执行结果决定：如果机器人在 T_{local} 步内成功抵达目标 g_t 附近，则 $y_t = 1$ ，否则 $y_t = 0$ 。RPN 通过最小化二元交叉熵损失 (BCE Loss) 进行更新：

$$\mathcal{L}_{reach} = -\mathbb{E}_{(S, g, y) \sim \mathcal{D}}[y \log M_{reach}(g) + (1 - y) \log(1 - M_{reach}(g))] \quad (3)$$

这种机制赋予了系统“从失败中学习”的能力，使其随着探索的进行逐渐掌握环境的拓扑特性。

3.4 多通道语义奖励机制

为了解决大场景下稀疏奖励导致的探索效率低下问题，我们设计了一个包含四项分量的综合奖励函数 R_{total} ，用于训练全局策略网络的 Actor 和 Critic：

$$R_{total} = R_{map} + \lambda_{sem} R_{sem} + \lambda_{struct} R_{struct} + \lambda_{front} R_{front} \quad (4)$$

其中 λ 为各分量的平衡系数。各奖励项的具体定义如下：

3.4.1 基础覆盖奖励 (R_{map})

衡量纯几何层面的信息增益，定义为当前时刻 t 新探索的自由空间面积：

$$R_{map} = \beta \cdot (\text{Area}(M_{exp}^t) - \text{Area}(M_{exp}^{t-1})) \quad (5)$$

该项保证了最基本的地图覆盖任务。

3.4.2 语义密度奖励 (R_{sem})

为了引导机器人深入高信息量区域，我们计算“新鲜区域”（可见但未访问区域 M_{fresh} ）内的语义密度总和：

$$R_{sem} = \frac{1}{N_{active}} \sum_{(i,j) \in M_{fresh}} S_{i,j} \quad (6)$$

该奖励激励智能体优先探索包含丰富语义对象（如家具、设备）的区域，从而提高探索的“信息含金量”。

3.4.3 结构感知奖励 (R_{struct})

针对大场景中常见的“狭窄通道穿越”与“房间切换”难题，我们对局部地图进行形态学分析，识别出门框（Door）、狭窄通道（Narrow）和开阔区域（Open）三类结构。奖励函数定义为：

$$R_{struct} = (w_{door} \cdot \mathbb{I}_{door} + w_{narrow} \cdot \mathbb{I}_{narrow} + w_{open} \cdot \mathbb{I}_{open}) \odot M_{fresh} \quad (7)$$

其中 $\mathbb{I}$ 为结构指示函数。我们将门框权重 w_{door} 设为最高，强力引导智能体突破局部封闭空间。

3.4.4 前沿驱动奖励 (R_{front})

为了减少回溯，我们识别已探索区域与未知区域交界的前沿点（Frontiers）。若检测到的前沿区域邻近门框结构，我们会施加额外的探索增益（Room Exploration Boost），以加速跨房间的拓扑探索。

3.5 语义回环检测与场景补全

在大尺度环境的长期运行中，为了抑制定位漂移并提升地图的完整性，系统集成了语义回环检测与场景补全模块。

3.5.1 语义回环检测

不同于容易受视角变化影响的传统视觉回环，我们采用 NetVLAD 提取场景的全局语义描述符，并结合局部语义指纹（检测到的物体类别分布）进行双重匹配。当检测到回环时（相似度 $\text{Sim}(f_t, f_{key}) > \tau$ ），通过后端优化（Pose Graph Optimization）校准全局地图，消除累积误差。

3.5.2 语义场景补全 (Semantic Scene Completion)

针对单帧观测中存在的视野盲区 (Blind Spots)，我们引入了语义场景补全机制。该模块利用室内环境的结构化先验（如墙壁的正交性、家具的物理尺寸约束），对 Neural SLAM 输出的稀疏 2D 语义地图进行实时预测。通过“幻觉”出盲区内的潜在几何结构（如推断墙后的空间延伸），该机制为全局规划器提供了更完整的环境上下文信息，有效降低了因遮挡导致的重复探索率。